







BÁO CÁO BÀI TẬP LỚN

MÔN HỌC MÁY


THÀNH VIÊN NHÓM


Tên	MSSV
NGUYỄN MINH HẠNH	2310895
TRẦN MINH TRÍ	2310627
HUỲNH CẨM LY	2312008
PHẠM THANH TÍN	2313459




MỤC LỤC NỘI DUNG



- Tổng quan về bài toán
 - Dữ liệu & Tiền xử lý
 - Các mô hình áp dụng
 - Thực nghiệm & So sánh kết quả
 - Kết luận & Hướng phát triển
- 
- 



TỔNG QUAN VỀ BÀI TOÁN

- Thực trạng: Bệnh tim mạch là nguyên nhân tử vong hàng đầu toàn cầu.
 - Vấn đề: Cần chẩn đoán sớm và chính xác để điều trị hiệu quả.
 - Giải pháp (Học máy): Phân tích dữ liệu y tế phức tạp, hỗ trợ bác sĩ ra quyết định nhanh chóng.
 - Mục tiêu: Xây dựng & so sánh các mô hình học máy để dự đoán nguy cơ mắc bệnh tim.
- 
- 
- 

TỔNG QUAN DỮ LIỆU & THÁCH THỨC (EDA)

- Nguồn dữ liệu: Tập dữ liệu bệnh tim mạch (920 hồ sơ bệnh án, 15 đặc trưng lâm sàng)
- Đặc trưng sinh lý tiêu biểu: age (Tuổi), sex (Giới tính), trestbps (Huyết áp), chol (Cholesterol), thalach (Nhịp tim tối đa),...
- 3 Thách thức cốt lõi từ dữ liệu:
- Khuyết thiếu & Sai lệch logic: Thiếu hụt nghiêm trọng (cột ca thiếu 66.4%, thalach thiếu 52.8%) và có giá trị phi logic (huyết áp/cholesterol = 0).
- Nhiều & Ngoại lai (Outliers): Biên độ dao động lớn, dễ làm chệch hướng mô hình học máy.
- Mất cân bằng lớp (Class Imbalance): Tỷ lệ mẫu Bệnh/Không bệnh là 509/411, dễ gây thiên lệch (Bias) cho mô hình.


TIỀN XỬ LÝ DỮ LIỆU


- Làm sạch & Chuẩn hóa logic: Quy hoạch nhãn về bài toán phân loại nhị phân (0: Không bệnh, 1: Có bệnh).
- Chuyển các giá trị phi lý (Huyết áp, Cholesterol = 0) thành NaN để xử lý triệt để.
- Xử lý dữ liệu khuyết thiếu (Imputation): Sử dụng KNNImputer (k=5) thay vì Mean/Median để bảo toàn tính tương quan bệnh lý giữa các hồ sơ.
- Chuẩn hóa đặc trưng (Scaling): Áp dụng RobustScaler nhằm triệt tiêu tác động của giá trị ngoại lai (Outliers) – cực kỳ quan trọng với dữ liệu y sinh.
- Phân chia dữ liệu: Tách tập Train/Test (80/20) theo phương pháp Stratified Split (giữ nguyên tỷ lệ lớp nhãn).

CÂN BẰNG DỮ LIỆU

- Vấn đề: Tập dữ liệu bị mất cân bằng (nguy cơ mô hình thiên lệch về nhóm đa số).
- Giải pháp: Áp dụng thuật toán SMOTE (Synthetic Minority Over-sampling Technique) để sinh mẫu nhân tạo cho nhóm thiểu số.
- Đảm bảo tính toàn vẹn (Data Leakage Prevention): SMOTE chỉ được áp dụng duy nhất trên Tập huấn luyện (Training set).
- Kiểm chứng bằng không gian PCA 2D: * Dữ liệu sinh ra hòa hợp hoàn hảo vào phân bố thực tế của nhóm thiểu số.
- Không tạo ra các nhiễu loạn xa lạ.


CÂN BẰNG DỮ LIỆU






FEATURE SELECTION

- Nguyên nhân: Không gian đặc trưng bị mở rộng mạnh sau khi mã hóa One-Hot, dễ dẫn đến quá khớp (Overfitting).
- Phương pháp áp dụng: Kỹ thuật SelectKBest.
- Tiêu chí đánh giá: Sử dụng Mutual Information thay vì ANOVA truyền thống.
- Lý do: Nắm bắt tốt các mối quan hệ phi tuyến tính phức tạp giữa triệu chứng lâm sàng và bệnh lý.
- Kết quả: Rút trích thành công 15 đặc trưng có Information Gain (điểm số thông tin) cao nhất để đưa vào huấn luyện.



Mô HÌNH DECISION TREE

- Nguyên lý: Phân nhánh dữ liệu theo điều kiện đặc trưng -> Cấu trúc cây.
 - Tham số chính: max_depth, min_samples_split, min_samples_leaf, max_features, criterion.
 - Ưu điểm: Trực quan, dễ giải thích, không cần chuẩn hóa.
 - Nhược điểm: Dễ bị Overfitting, nhạy cảm với nhiễu.
- 
- 
- 

ĐÁNH GIÁ BASELINE


- Thiết lập: Cây quyết định mặc định (Không giới hạn độ sâu).
- Kết quả phân loại:
- Độ chính xác Tập huấn luyện (Train Acc): 100%
- Độ chính xác Tập kiểm tra (Test Acc): 76.63%
- Vấn đề phát hiện: Khoảng cách quá lớn giữa Train và Test chứng tỏ mô hình đang bị Overfitting (Quá khớp) nặng.
- Giải pháp: Cần kiểm soát độ phức tạp của cây và tinh chỉnh siêu tham số.

TỐI ƯU HÓA SIÊU THAM SỐ


- Bước 1 - Tìm kiếm thô (RandomizedSearchCV): Lấy mẫu 200 tổ hợp ngẫu nhiên trên không gian tham số rộng để khoanh vùng tiềm năng, tiết kiệm thời gian tính toán.
- Bước 2 - Tìm kiếm tinh (GridSearchCV): Dò tìm vết cạn trong vùng hẹp để chốt bộ tham số tối ưu nhất.
- Bộ tham số chốt: `max_depth = 9`, `min_samples_leaf = 12`, `min_samples_split = 6`, `max_features = None`.

Phân tích độ nhạy của từng siêu tham số (Coarse Tuning)


Max Depth




Min Samples Split



Min Samples Leaf




Max Features






TỐI ƯU NGƯỠNG QUYẾT ĐỊNH

- Mục tiêu: Cân bằng giữa độ chính xác tổng thể (Accuracy) và khả năng nhận diện đúng ca bệnh (F1-Score) với tỷ lệ 50/50.
- Thực hiện: Thử nghiệm dải ngưỡng dự đoán từ 0.25 đến 0.70.
- Kết quả: Ngưỡng tối ưu dịch chuyển từ 0.50 (mặc định) xuống 0.37.
- Ý nghĩa: Việc hạ ngưỡng giúp mô hình "nhạy cảm" hơn, phù hợp với bài toán y tế (hạn chế tối đa việc bỏ sót bệnh nhân mắc bệnh).





KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH (SAU TÍNH CHỈNH)

- Mô hình đã khắc phục triệt để lỗi Overfitting và tăng vọt độ chính xác.
 - Accuracy: Tăng từ 76.63% lên 82.61%
 - ROC-AUC: Tăng từ 0.7629 lên 0.8873
 - F1-Score: Tăng từ 0.7902 lên 0.8519
 - Độ nhạy - Sensitivity: Đạt 90.20%, chứng tỏ mô hình dự đoán trúng 90% số người thực sự mắc bệnh tim.
- 
- 





CÁC ĐẶC TRƯNG QUAN TRỌNG & CẤU TRÚC MÔ HÌNH






Mô HÌNH LOGISTIC REGRESSION

- Nguyên lý: Ước lượng xác suất phân lớp dựa trên hàm Sigmoid.
 - Tham số chính: C (Kiểm soát Regularization), solver.
 - Ưu điểm: Đơn giản, tính toán nhanh, cho ra xác suất dự đoán rõ ràng.
 - Nhược điểm: Giả định quan hệ tuyến tính, kém hiệu quả với dữ liệu phức tạp.
- 
- 
- 






ĐÁNH GIÁ BASELINE

- Thiết lập: Logistic Regression mặc định ($C=1.0$, `solver='lbfgs'`, `max_iter=1000`, `penalty='l2'`).
 - Dữ liệu: Huấn luyện trên 814 mẫu (15 đặc trưng), đánh giá trên 184 mẫu.
 - Độ chính xác Tập kiểm tra (Test Acc): 83.70%
 - Nhận xét: Không có hiện tượng Overfitting — mô hình tuyến tính tổng quát hóa tốt ngay từ cấu hình mặc định, không cần hyperparameter tuning.
- 
- 
- 


KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH

- Accuracy: 83.70% (phân loại đúng 154/184 mẫu)
- ROC-AUC: 0.896 — xác suất 89.6% xếp hạng đúng một cặp mẫu ngẫu nhiên.
- Sensitivity (Recall): 0.87 — nhận diện đúng 89/102 bệnh nhân mắc bệnh.
- Specificity: 0.79 — xác định đúng 65/82 bệnh nhân khỏe mạnh.
- F1-Score: 0.86 (Có bệnh) | 0.81 (Không bệnh)





Mô HÌNH RANDOM FOREST

- Nguyên lý (Ensemble): Kết hợp nhiều cây quyết định độc lập (Bootstrap) -> Bỏ phiếu đa số.
 - Tham số chính: `n_estimators`, `max_depth`, `min_samples_leaf`.
- 
- 
- 

CƠ CHẾ HOẠT ĐỘNG VÀ ƯU/ NHƯỢC ĐIỂM

Cơ chế hoạt động

- **Bootstrap Sampling**

Lấy mẫu ngẫu nhiên có hoàn lại
→ 100 tập con từ 920 mẫu

- **Feature Randomness**

Tại mỗi nút, chọn ngẫu nhiên $\sqrt{28}$
 ≈ 5 đặc trưng để tách

- **Majority Voting**


Kết quả cuối = đồng thuận đa số
100 cây → Giảm variance

Ưu điểm

- Bền vững với dữ liệu nhiễu & giá trị khuyết
- Cung cấp Feature Importance cho bác sĩ
- Kháng Overfitting tốt hơn cây đơn lẻ
- Ổn định (CV std chỉ $\pm 1.8\%$)

Nhược điểm

- Tốn tài nguyên tính toán hơn cây đơn
- Khó giải thích từng quyết định cụ thể
- Specificity (81.71%) thấp hơn Recall



TINH CHỈNH VÀ TỐI ƯU HÓA

Grid Search

n_estimators

100

số cây đủ lớn → dự
đoán ổn định

max_depth

20

Giới hạn độ sâu → tránh
học vẹt nhiều

min_samples_leaf

2

Mỗi lá ≥ 2 mẫu → tăng
tổng quát hóa

10 - Fold Cross Validation

Accuracy trung bình: 83.42% | Độ lệch chuẩn: $\pm 4.13\%$ → Mô hình ổn định & tin cậy

KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH

ACCURACY

87.5%

184 mẫu test

ROC - AUC

0.9189

Phân loại xuất sắc

SENSITIVITY

92.16%


Chỉ bỏ sót 8 ca bệnh

SPECIFICITY

81.71%


17 ca âm tính giả

Confusion Matrix




KẾT QUẢ THỰC NGHIỆM


- Chỉ số đánh giá: Accuracy, Precision, Recall, F1-Score, AUC-ROC.
- Điểm nhấn thực nghiệm:
- Mô hình tốt nhất - Random Forest: Accuracy cao nhất (87.5%), F1 (0.89), AUC (0.9189).
- Phù hợp y tế nhất - Logistic Regression: Recall cao nhất (0.89)
→ Tối ưu việc giảm thiểu bỏ sót ca bệnh.
- Kém hiệu quả nhất - Decision Tree: Accuracy thấp (82.1%), có xu hướng overfitting.



KẾT LUẬN

Học máy chứng minh được tiềm năng lớn trong chẩn đoán y tế sớm.


- Thử nghiệm SVM (tối ưu phân loại không gian đa chiều).
 - Áp dụng Deep Learning (Neural Networks) & XGBoost để tối đa hóa độ chính xác.
- 



HƯỚNG PHÁT TRIỂN

Thử nghiệm thêm các mô hình học máy khác như Support Vector Machine (SVM) để tận dụng khả năng phân loại mạnh mẽ trong không gian đa chiều.

Áp dụng Neural Networks và XGBoost để khai thác sức mạnh của deep learning và gradient boosting, có thể cải thiện đáng kể độ chính xác chẩn đoán.





XIN CẢM
ƠN !